De la voz al texto con modelos abiertos

Transcripción automática para antropología, sociología y psicología

Ciencia de Datos con Python

Universidad del Pacífico · Departamento de Economía

Sesión 13

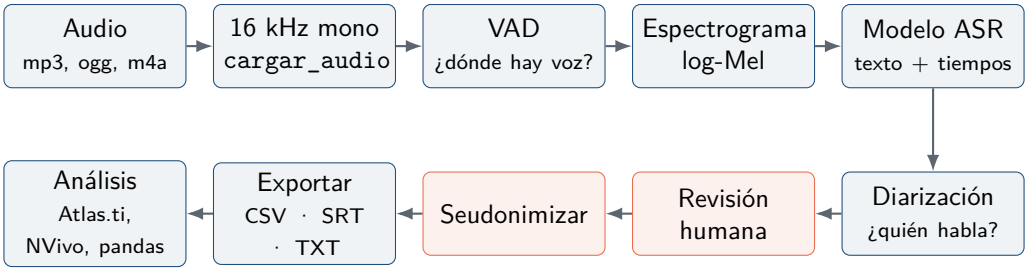
¿Por qué importa en ciencias sociales?

- Transcribir a mano toma 4 a 8 horas por cada hora de grabación.
- Entrevistas en profundidad, grupos focales, historias de vida, testimonios, sesiones clínicas.
- Un modelo hace el primer borrador en minutos; la persona investigadora revisa.

Por qué modelos abiertos y locales

- La voz es un dato personal (Ley N.° 29733).
- Si el audio no sale de tu máquina, el comité de ética no tiene que preguntar adónde fue.
- Sin pago por minuto ni cuenta en la nube.

El pipeline



El VAD (Silero, 2 MB) cumple tres funciones: corta audios largos, evita darle silencio al modelo (ahí inventa) y da las unidades para separar hablantes. Naranja: pasos que no se automatizan.

Tres familias de modelos

Familia	Cómo funciona	Consecuencia
Codificador-decodificador Whisper, Qwen3-ASR, Voxtral	Un codificador lee el espectrograma; un decodificador *escribe* palabra por palabra, como un LLM.	Puntúa bien y usa contexto, pero puede inventar.
Transductor (TDT) Parakeet	En cada instante decide si emite una palabra o avanza en el audio.	Muy rápido; el texto queda anclado al sonido.
CTC MMS, Omnilingual	Asigna una letra (o nada) a cada 20 ms de audio.	Simple, sin puntuación; se adapta a lenguas nuevas con pocos datos.

Modelos abiertos que vale la pena conocer (2026)

Modelo	Autor	Licencia	Idiomas	Para qué
Whisper large-v3-turbo	OpenAI (EE. UU.)	MIT	99	el estándar; traduce al inglés
faster-whisper	SYSTRAN	MIT	99	Whisper en CPU (int8), cualquier laptop
Qwen3-ASR 0.6B / 1.7B	Alibaba (China)	Apache 2.0	30 + 22 dial.	preciso; acepta contexto
Parakeet TDT 0.6B v3	NVIDIA (EE. UU.)	CC BY 4.0	25 europeos	el más rápido
Voxtral Mini 4B Realtime	Mistral (Francia)	Apache 2.0	13	en vivo (streaming)
MMS-1b-all	Meta (EE. UU.)	CC BY-NC 4.0	1 162	quechua, aimara, amazónicas
Omnilingual ASR	Meta (EE. UU.)	Apache 2.0	1 600+	sucesor de MMS (Linux)

Más modelos chinos: SenseVoice y Fun-ASR (Alibaba), FireRedASR2 (Xiaohongshu), GLM-ASR (Zhipu), Paraformer. Especializados en mandarín y dialectos; SenseVoice además etiqueta emociones y risas.

Todos en Hugging Face y todos ejecutables con `transformers`. Ranking: Open ASR Leaderboard (hf-audio).

Medido en clase: Mac M5 Max, español peruano

30 s de entrevista (El Agustino)

Modelo	Segundos	Disp.
Parakeet v3	0,48	GPU
Whisper turbo	1,43	GPU
Qwen3-ASR 0.6B	1,54	GPU
faster-whisper	5,15	CPU
Voxtral (por lotes)	14,0	GPU

Entrevista simulada de 106 s

dos personas reales de OpenSLR 73, con verdad conocida

Modelo	WER	Hablantes
Parakeet v3	3,3 %	100 %
faster-whisper	3,9 %	100 %
Qwen3-ASR 0.6B	4,6 %	100 %
Whisper turbo	7,2 %	100 %

WER = (sustituidas + borradas + insertadas) / palabras reales. 5 % = una palabra mal cada veinte.

Darle contexto al modelo

Dos vendedoras dicen su nombre (3 segundos de audio, Qwen3-ASR):

Sin contexto

```
¿Sabes? Sabes el básquet. Sabes a barrientos.
```

Con `contexto="Isabel Vásquez, Elsa Barrientos"`

```
Isabel Vásquez Elsa Barrientos
```

Los nombres propios y la jerga son lo que más falla, y casi siempre los conocemos de antemano (ficha de campo, consentimiento informado). Whisper y Qwen3-ASR aceptan esa lista.

Alucinaciones: el modelo escucha lo que no hay

Audio sin voz	Whisper escribe
10 s de silencio	«Gracias por ver el video.»
10 s de ruido suave	«¡Suscríbete al canal!»
silencio, sin idioma	«Thank you.»
con VAD activado	(nada)

- Whisper aprendió de subtítulos de YouTube.
- *Careless Whisper* (Koenecke et al., FAccT 2024): frases inventadas en $\sim$1 % de los audios; 38 % de ellas dañinas.
- Pasa en pausas largas: personas mayores, terapia, testimonios difíciles.

Regla: VAD siempre activado y toda cita textual se verifica contra el audio.

Lenguas originarias: quechua de Huaylas (Shansha, Áncash)

Entrevista sobre plantas medicinales, proyecto comunitario *Qurakuna Rimaykuy* (Wikimedia Commons, CC BY-SA 4.0).

Whisper (no conoce el quechua): inventa castellano

`¿Y cómo se llama Houti? Houti, Marcilina Figueroa. ¿Y qué plantas de medicina? …`

MMS con el adaptador `qwh`

`… imataq juticun que planta … awrinsha sirbin inframasion …`

Adaptadores MMS en el Perú: `quy` Ayacucho, `quz` Cusco, `qwh` Huaylas, `qxn`/`qxo` Conchucos, `qvw` Huaylla Wanca, `ayr` aimara, `shp` shipibo-konibo, `cni` asháninka, `agr` awajún, `mcb` matsigenka.

Validar con hablantes de la variedad: no hay transcripción de referencia, MMS aprendió de lecturas bíblicas y no puntúa.

¿Quién habla? Diarización en tres pasos

1. Cortar en tramos de voz (VAD o segmentos del ASR).
2. **Huella de voz** de cada tramo: 256 números (WeSpeaker).
3. Agrupar huellas parecidas (clustering con distancia coseno).

Tramos de menos de 1 s («sí», «ajá») dan huellas poco fiables: se asignan al final.

Entrevista 2, El Agustino

- 189 s, sin decirle cuántas personas hay.
- Separó al entrevistador y a las dos vendedoras.
- Salida: tiempo de habla, turnos y palabras por minuto de cada persona.

Para habla superpuesta: `pyannote community-1` (CC BY 4.0, local; pide aceptar condiciones).

Transcripción en vivo

Estrategia	Cómo	Retraso	Ejemplos
Esperar la pausa	el VAD detecta el fin de la frase y se transcribe	1–3 s	faster-whisper + Silero
Ventana deslizante	re-transcribe el último tramo cada segundo	1–2 s	whisper_streaming, WhisperLiveKit
Modelo de streaming	entrenado para escribir con el audio a medias	0,1–0,5 s	Voxtral Realtime, Kyutai STT, Moonshine

Medido: Voxtral en la GPU de la Mac escribe cada palabra unos 0,04 s después de recibir el audio (más 0,48 s de espera por diseño). Necesita generar 12,5 tokens/s: sin GPU, usar «esperar la pausa».

```
uv run python sessions/13-audio-a-texto/app/en_vivo.py
```

Aplicaciones en el Perú

Antropología

- Etnobotánica y saberes locales en quechua
- Historia oral y memoria
- Radio comunitaria
- Archivos de testimonios (p. ej., CVR)

Sociología

- Grupos focales con turnos
- Audiencias públicas, Congreso, consejos regionales
- Mensajes presidenciales y debates
- Entrevistas en la calle

Psicología

- Sesiones y entrevistas clínicas, solo en local
- Velocidad del habla, pausas, turnos
- Tareas de fluidez verbal
- Cautela: errores no aleatorios

Exportar en **SRT**: Atlas.ti, MAXQDA, NVivo y ELAN lo sincronizan con el audio (clic en la cita, suena el fragmento).

¿Qué modelo uso?

Situación	Recomendación
Laptop sin GPU, castellano o inglés	faster-whisper turbo, int8, con VAD
Mac con chip M o GPU NVIDIA, mucho audio	Parakeet v3 o Qwen3-ASR
Nombres propios, siglas, jerga	Qwen3-ASR o Whisper con contexto
Quechua, aimara, lenguas amazónicas	MMS (u Omnilingual ASR); validar con hablantes
En vivo (clase, asamblea, audiencia)	Voxtral Realtime con GPU; si no, esperar la pausa
Traducir al inglés	Whisper con `task="translate"`
Mandarín y dialectos chinos	Qwen3-ASR, FireRedASR2, SenseVoice
Audio muy sensible	cualquiera, siempre local

Antes de usarlo en una investigación

1. **Consentimiento informado**: decir que el audio se transcribe con software y dónde se procesa.
2. **Procesar en local** y guardar los audios cifrados: la voz identifica más que el texto.
3. **Seudonimizar** antes de compartir; el modelo escribe un nombre de varias formas (Vásquez, Vázquez).
4. **Revisar todo lo que se cita** contra el audio. Los errores se concentran en acentos regionales, personas mayores, habla con dificultades y cambio de código quechua-castellano.
5. **Reportar** en la metodología el modelo, la versión y cuánto se revisó a mano.

Referencias

- Radford et al. (2022). *Robust Speech Recognition via Large-Scale Weak Supervision* (Whisper). arXiv:2212.04356.
- Qwen Team (2026). *Qwen3-ASR*. github.com/QwenLM/Qwen3-ASR.
- NVIDIA (2025). *Parakeet TDT 0.6B v3*. huggingface.co/nvidia/parakeet-tdt-0.6b-v3.
- Mistral AI (2026). *Voxtral Realtime*. arXiv:2602.11298.
- Pratap et al. (2023). *Scaling Speech Technology to 1,000+ Languages* (MMS). arXiv:2305.13516.
- Omnilingual ASR Team (2025). *Omnilingual ASR*. arXiv:2511.09690.
- Koenecke, Choi, Mei, Schellmann y Sloane (2024). *Careless Whisper: Speech-to-Text Hallucination Harms*. FAccT.
- Datos: OpenSLR 73 (español peruano, CC BY-SA 4.0); FLEURS (CC BY 4.0); entrevistas de Wikimedia Commons (CC BY-SA 4.0): El Agustino (Wikimedia Perú), Shansha (*Qurakuna Rimaykuy*), Minnesota State University, Mankato.

Código: `sessions/13-audio-a-texto/` · tutorial: `lecture/tutorial_corto_audio_a_texto.ipynb`